



YAZILIM MÜHENDİSLİĞİ GÖRÜNTÜ İŞLEME

ÖZGE GÜRBÜZ

MAYIS , 2023

1.Giriş

Dijital manipölasyonlar sonucunda oluşturulan sahte görüntü ve video içeriklerinin sayısı giderek artmaktadır. Dijital manipölasyonlar fotoğraf ve videolarda başlangıçta insanları eğlendirmek amacıyla geleneksel yöntemler kullanılarak yapılmaktaydı. Günümüzde ise dijital manipölasyonlar için makine öğrenmesi algoritmaları kullanılmaya başlanmıştır. Makine öğrenmesi algoritmalarının kullanılması ile gerçek içerikler ile sahte içeriklerin ayırt edilebilmesi oldukça zorlaşmıştır [1,8].

Yüz manipölasyonları, dijital manipölasyonlar arasında en yaygın türdür. Yüz manipölasyonları ile kişiler hiç bulunmadıkları bir yerde gösterilebilir veya hiç yapmadıkları konuşmalar yaptırılabilir. Yüz manipölasyonları tüm yüz sentezi, kimlik değiştirme, nitelik manipölasyonu ve ifade değiştirme olmak üzere dört temel gruba ayrılır [2,8].

Bu proje,transfer öğrenme, evrişimli sinir ağları ve sahte yüz algılama gibi konular üzerine yapılan araştırmaların bir örneğini temsil eder.Böylece dijital manipölasyonlar sonucunda oluşturulan sahte yüz görüntüleri ayrıştırılır.

2.Literatür Özeti

Literatürde tüm yüz sentezi manipölasyon yöntemi için hafif derin öğrenme temelli bir çalışma bulunmamaktadır. Tüm yüz sentezi manipölasyon tespiti için MobileNet, MobileNetV2, EfficientNetB0 ve NASNetMobile evrişimsel sinir ağları kullanılmıştır. Modeller ImageNet veri seti üzerinde ön eğitilmiş olarak transfer öğrenme ile tekrar kullanılmıştır.

3.Materyal ve Metot

Bu bölümde metotlar ve materyaller hakkında bilgiler verilmektedir.VGG16 ve VGG19 CNN ağ modeli import edilmiştir.**VGG16** ve **VGG19** CNN ağ modelinin **ImageNet** veri seti ile eğitildiği ağ ağırlıkları modele yüklemiştir.

Bu çalışma, transfer öğrenme kullanarak önceden eğitilmiş bir evrişimli sinir ağı modelini (Convolutional Neural Network - CNN) eğitmek için oluşturulmuştur. Transfer öğrenme, bir önceden eğitilmiş modelin özellik çıkarmak için kullanılması ve ardından çıkarılan özelliklerin sınıflandırma için yeni bir sinir ağına beslenmesini içerir.

VGG16 ve VGG19 modelleri kullanılarak önceden eğitilmiş bir CNN modeli olan conv_base oluşturulur. Bu model, ImageNet veri kümesi üzerinde eğitilmiştir. Modelin özetini göstermek için summary() fonksiyonu kullanılır.

Daha sonra, hangi katmanların eğitileceği ve dondurulacağı belirlenir. 'block5_conv1' katmanına kadar olan tüm katmanlar dondurulur. Ardından, bir boş model (model) oluşturulur.

Oluşturulan conv_base modeli, model'e eklenir. Ardından, Flatten() katmanı kullanılarak matrisler vektörlere dönüştürülür. Ardından, bir gizli katman (Dense) ve çıkış katmanı eklenir. Gizli katmanda ReLU aktivasyon fonksiyonu kullanılırken, çıkış katmanında softmax

aktivasyon fonksiyonu kullanılır. Bu, modelin iki sınıf olan "fake" ve "real" sınıflarını sınıflandırmasını sağlar.

Model derlenirken `binary_crossentropy`(ikili çapraz entropi) kayıp fonksiyonu ve `RMSprop` optimizier kullanılır. Ayrıca, eğitim sırasında doğruluk (accuracy) metriği izlenir.

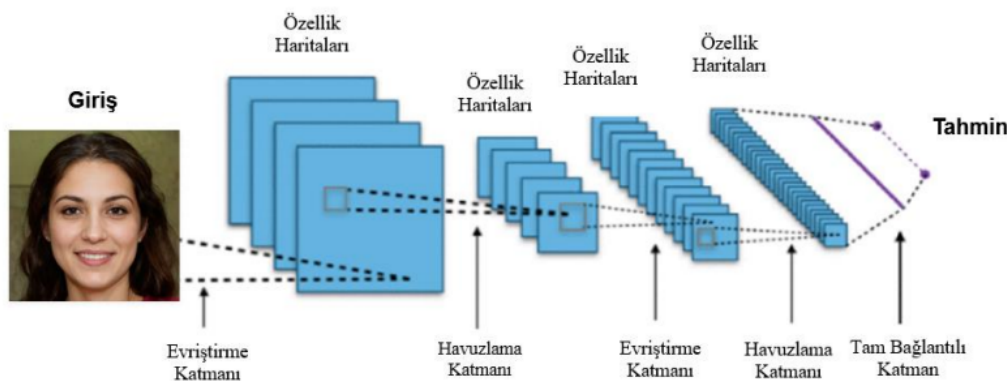
Overfitting'i önlemek için eğitim verilerine veri artırma işlemleri uygulanır. Eğitim verileri, `ImageDataGenerator` kullanılarak ölçeklendirilir. `rescale`, `rotation_range`, `width_shift_range`, `height_shift_range`, `shear_range`, `zoom_range`, `horizontal_flip` gibi parametrelerle çeşitli veri artırma teknikleri uygulanır. Benzer şekilde, doğrulama verileri de ölçeklendirilir.

Model eğitimi `fit()` fonksiyonu kullanılarak gerçekleştirilir. Eğitim ve doğrulama veri akışları ile adım sayıları (`steps_per_epoch`, `validation_steps`) ve epoch sayısı belirtilir. Eğitim sırasında elde edilen kayıp ve doğruluk değerleri `history` değişkenine kaydedilir, grafiklerle görselleştirilir.

Eğitim tamamlandıktan sonra, eğitilen model 'fakeFaceDetection.h5' adıyla kaydedilir ve test verileri üzerinde değerlendirme yapılır. Test verileri için de `ImageDataGenerator` kullanılır ve `rescale` parametresi kullanılarak piksel değerleri 0-1 aralığına ölçeklenir, bir veri akışı (`test_generator`) oluşturulur. `evaluate()` fonksiyonu kullanılarak kayıp ve doğruluk değerleri elde edilir.

Aynı zamanda eğitim sürecini izlemek için grafikler oluşturulur. İlk grafik, eğitim doğruluğunu ve doğrulama(geçerleme) doğruluğunu epoch sayısına göre gösterir. İkinci grafik ise eğitim kaybını ve doğrulama kaybını epoch sayısına göre gösterir (Şekil 8 ve 10).

Son olarak, tahmin işlemi gerçekleştirilir. Tahminler, `model.predict()` fonksiyonu kullanılarak elde edilir ve ardından `argmax()` fonksiyonu kullanılarak en yüksek olasılığa sahip sınıflar belirlenir. Bu tahminler ve gerçek etiketler arasındaki karşılaştırmalar için Confusion Matrix hesaplanır ve görselleştirilir.



Şekil 1. Evrişimsel sinir ağının çalışması [8]

3.1.Görüntü İşleme

Görüntü işleme, sinyal işlemenin önemli alanlarından biridir. Gerçek yaşamdaki belirli görüntülerin bazı aşamalardan geçerek, bu görüntülerden anlamlı bir bilgi çıkarımı yapılmasıdır [3,4,5].

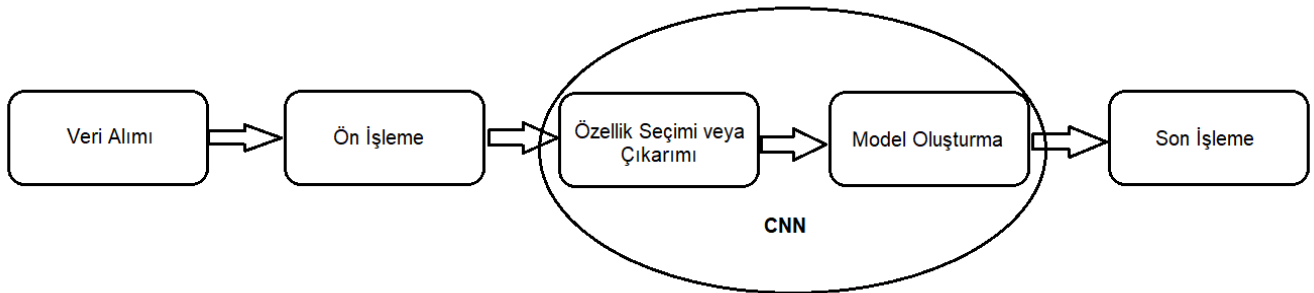
Bu bağlamda Şekil 2’de gösterildiği gibi, görüntü verileri bazı temel aşamalardan geçer. Bu aşamalar ise; görüntü elde etme, ön işleme, geliştirme ve görüntüleme, bilgi çıkarımıdır [6]. Bu aşamaların ardından ilgili giriş verilerinden ihtiyaca göre sonuçlar elde edilebilmektedir [7].



Şekil 2. Görüntü işleme temel aşamaları [6]

Temel olarak kamera ve algılayıcılar vasıtasıyla elde edilen görüntüde ilgili nesne ve örüntülerin tanınabilmesi için genel bir şablon olarak izlenmesi gereken basamaklar ise şunlardır:

- Ön İşleme
- Özellik Seçimi veya Çıkarımı
- Eğitici (supervised) sınıflandırma veya eğitici (unsupervised) kümeleme yöntemleri kullanarak model altyapısının kurulumu
- Son İşleme




Şekil 3. Nesne ve örüntü tanıma için genel akış şeması

3.1.1. Veri Alma ve Oluřturma


Sahte yüz görüntülerini tespit edebilmek için evriřimsel sinir aęları kullanılmıřtır. Evriřimsel sinir aęı modelini eęitmek için **4200** görüntüden oluřan veri seti kullanılmıřtır. Kullanılan veri seti hazır Real and Fake Faces veri setlerindeki **2100** gerek ve **2000** sahte yüz görüntülerinden oluřturulmuřtur. **100** sahte yüz görüntüsü ise *Stable Diffusion** ile metinden resim ve resimden resim türünden üretilerek veri setine eklenmiřtir. Bu veri seti ekiřmeli üretici aęlar için hazırlanmıř yař ve farklı etnik köken eřitlilięine sahip yüksek özünürlüklü görüntülerden oluřan veri setidir.

Anita Rác vd. [7] tarafından yapılan alıřmada %80 eęitim ,%20 test veri seti bölme oranında model performansının maksimuma ulařtıęı görölmüřtür. Bu nedenle öncelikle veri setindeki görüntülerin %80'i eęitim, %20'si test iřlemi için kullanılmıřtır [7]. Daha sonra ise aęın Overfitting yapmasını engellemek için veri setinin eęitim, test ve doęrulama(geerleme) olmak üzere 3'e ayrılmasına karar verilmiřtir. Buradaki aęırlıklandırma ise %64 eęitim ,%20 test ve %16 doęrulama olarak ayarlanmıřtır. İlgili veri setlerinin baęlantıları kaynaka bölümünde verilmiřtir. Veri setindeki bazı örnekler ařaęıda řekil 4 ve 5'te verilmiřtir.

**Stable Diffusion, derin öęrenme altyapılı bir metin giriřinden görüntüler oluřturan yapay zeka modelidir. Öncelikle metin aıklamalarına baęlı olarak ayrıntılı görüntüler oluřturmak için kullanılır, ancak görüntünün ierięini deęiřtirmek ya da dıřını geniřletmek gibi dięer görevlerde de uygulanabilir. [9]*



Şekil 4. Veri setinde yer alan sahte yüz örnekleri



Şekil 5. Veri setinde yer alan gerçek yüz örnekleri

3.1.2. Ön İşleme

Hem eğitim hem de doğrulama verileri VGG16 ve VGG19 giriş katmanı boyutlarına uygun olacak şekilde 224x224 çözünürlüğünde ölçeklendirilmiştir (gerçek boyutlar 256*256). “batch_size” argümanı her yüklemede 32 resim çekilecek şekilde ayarlanmıştır. Ayrıca veri üreteçleri kullanarak piksel değerlerini 0-255'den 0-1 arasına getirme, verileri kırpma, zoom yapma, girişleri yatay ve dikey olarak rastgele çevirme, girdi sınırları dışındaki noktaları verilen moda göre doldurma, tersine çevirme gibi veri büyütme teknikleri kullanarak veri sayıları artırılmış ve işlenmiştir.

3.1.3. Özellik Çıkarma

Özellik seçimi ve çıkarımında verinin ayrıştırıcılığını kaybetmeden veya mümkünse artırarak olabildiğince az sayıda öznelik kullanılarak sınıflandırma ve kümeleme başarımının artırılması hedeflenir. Özellik çıkarma işlemi Derin Öğrenmede evrişim ve havuzlama işlemleri ile gerçekleştirilir. Transfer öğrenme modeli ile de bu işlemler direkt olarak alınabilir. Bu çalışmada kullanılan modeller ise VGG16 ve VGG19 'dır ve ImageNet ağırlıkları kullanılmıştır.

3.1.4. Model Oluşturma

Öncelikle oluşturulan boş modelin ilk katmanına özellik çıkarılmış katman eklenmiştir. Daha sonra Flatten(düzleştirme) işlemi yapılmıştır. Bu işlemle birlikte çok boyutlu veriler yan yana sıralanarak bir boyutlu vektör haline getirilmiştir. Sonrasında sınıflandırıcı nöronlar eklenir. En sonda ise iki sınıf olduğu ve sınıflandırma yapılacağı için softmax aktivasyon fonksiyonu ile 2 nöron kullanılır. Ve model derlenir(Derleme, kayıp işlevini, optimize ediciyi ve metrikleri tanımlar). Derleme işlemi tamamlandıktan sonra modelin eğitimi yapılmıştır.

Layer (type)	Output Shape	Param #
=====		
vgg16 (Functional)	(None, 7, 7, 512)	14714688
flatten_37 (Flatten)	(None, 25088)	0
dense_74 (Dense)	(None, 256)	6422784
dense_75 (Dense)	(None, 2)	514

Layer (type)	Output Shape	Param #
=====		
vgg19 (Functional)	(None, 7, 7, 512)	20024384
flatten (Flatten)	(None, 25088)	0
dense (Dense)	(None, 256)	6422784
dense_1 (Dense)	(None, 2)	514

Şekil 6. VGG16 ve VGG19 modelleri dahilinde oluşturulmuş modellerin özeti

3.1.5. Son İşleme


Elde edilen sınıflandırma veya kümeleme sonuçlarının iyileştirilmesi için yapılan her türlü işlem son işleme başlığı altında işlenebilir.

4. Deneyler Ve Bulgular


ImageNet ile ağırlıklandırılmış VGG16 ve VGG19 modelleri kullanımı sonucu toplam 4200 görüntüden, 100 epoch ile acc değerinde %89 ve %90 başarı elde edilmiştir. Bununla ilgili bazı grafikler aşağıdaki şekillerde verilmiştir.

	Gerçek Yüz Görüntüleri Sayısı			Sahte Yüz Görüntüleri Sayısı			Başarı (%)	
Model Adı	Eğitim	Doğrulama	Test	Eğitim	Doğrulama	Test	Test Acc	Test Loss
VGG16	1344	336	420	1344	336	420	78,9	54
VGG19	1344	336	420	1344	336	420	79,5	58


Şekil 7. Deneylerde kullanılan örnek sayıları ve başarı değerleri




Şekil 8. VGG16 modeli ile eğitim sonucu elde edilen, eğitim ve doğrulama acc ve loss değerlerinin grafikleri



Şekil 9. VGG16 modeli eğitimi sonucu elde edilen karmaşıklık matrisi



Şekil 10. VGG19 modeli ile eğitim sonucu elde edilen, eğitim ve doğrulama acc ve loss değerlerinin grafikleri



Şekil 11. VGG19 modeli eğitimi sonucu elde edilen karmaşıklık matrisi

Bu çalışma i7-13700H 2.40 GHz işlemci ,16GB DDR4 bellek ve 6GB Nvidia RTX4050 ekran kartına sahip bilgisayarda gerçekleştirilmiştir.

5.Sonuçlar

Bu çalışmada gerçek ve sahte yüzleri birbirinden ayıran, iki sınıfta toplanan ve toplamda sadece 2100 adet gerçek ve sahte yüz görüntülerinden oluşan veri seti ile önceden eğitilmiş CNN ağlarını kullanarak bir sınıflandırıcı yapılmıştır.

VGG16 ve VGG19 modellerinin çıkışındaki katmanları değiştirerek yapılan sınıflandırıcı %80 üzerinde doğruluk değerine ulaşmıştır.

Sonuç olarak bu çalışma, sahte yüz algılama gibi uygulamalarda kullanılabilecek bir temel sağlar ve başka veri kümeleriyle veya farklı sınıflarla genişletilebilir. Hiper-parametreler ile optimizasyon sürdürüldüğünde bu doğruluğu arttırmak mümkün olabilir. Ayrıca, farklı önceden eğitilmiş CNN modelleri kullanılarak da deneyler yapılabilir ve performans karşılaştırmaları yapılabilir.

KAYNAKÇA

- [1]. Pashine, S., Mandiya, S., Gupta, P. and Sheikh, R., "Deep Fake Detection : Survey of Facial Manipulation Detection Solutions", arXiv preprint arXiv:2106.126, 2021.
- [2]. Wang, R., Juefei-Xu, F., Ma, L., Xie, X., Huang, Y., Wang, J. and Liu, Y., "FakeSpotter: A Simple yet Robust Baseline for Spotting AI-Synthesized Fake Faces", arXiv preprint arXiv:1909.06122, 2020.
- [3]. Yaman, K., Sarucan, A., Atak, M., Aktürk, N., "Dinamik Çizelgeleme İçin Görüntü İşleme Ve Arama Modelleri Yardımıyla Veri Hazırlama", Gazi Üniv. Müh. Mim. Fak. Der., Cilt:16, No:1, 19-40, Vol 16, 2001.
- [4]. Karakoç, M., "Görüntü işleme, Teknolojiler ve Uygulamaları", https://ab.org.tr/ab12/sunum/21-goruntu_isleme-Karakoc.pdf, Akademik Bilişim'12-XIV, Uşak, 1-3 Şubat 2012.
- [5]. Öztaş, O., "Görüntü İşleme Teknikleri-I", <http://www.oguzhanoztas.com/gi/ders1.pdf>, 12 Şubat, 2019.
- [6]. DUMAN / INTERNATIONAL JOURNAL OF 3D PRINTING TECHNOLOGIES AND DIGITAL INDUSTRY (2019)
- [7]. DUMAN, B. GÖRÜNTÜ İŞLEME TEKNİKLERİNİN EKLEMELİ İMALATTA KULLANIMI.
- [8]. ŞAFAK, E., & BARIŞÇI, N. (2022). Hafif Evrişimsel Sinir Ağları Kullanılarak Sahte Yüz Görüntülerinin Tespiti. El-Cezeri, 9(4), 1282-1289.
- [9] https://tr.wikipedia.org/wiki/Stable_Diffusion

Veri Setlerinin Bağlantıları

1. <https://www.kaggle.com/datasets/xhlulu/140k-real-and-fake-faces>
2. <https://www.kaggle.com/datasets/uditsharma72/real-vs-fake-faces>